



UNIVERSIDAD AUTÓNOMA DE  
CHIHUAHUA

**UNIVERSIDAD AUTÓNOMA DE CHIHUAHUA**

Facultad de Ingeniería



Ingeniería en Ciencias de la Computación

**INTELIGENCIA ARTIFICIAL 9CC4**

## **Proyecto Predicción de Forma de Rostro con Imágenes**

**Trabajo de:**

- JOSÉ ANGEL ORTÍZ MERAZ [353195]
- JOCELYN SOTO ÁVILA [348687]

**Asesor:** MANUEL ALBERTO CHAVEZ SALCIDO

*24 de mayo de 2025*

## Introducción

El machine learning (ML) es una rama de la inteligencia artificial (IA) y la informática que se centra en el uso de datos y algoritmos para permitir que la IA imite la forma en que los humanos aprenden, mejorando gradualmente su precisión.

En general, los algoritmos de machine learning se utilizan para hacer una **predicción** o **clasificación**. Con base en algunos datos de entrada, que pueden estar **etiquetados** o no **etiquetados**, un algoritmo de machine learning producirá una estimación sobre un patrón en los datos.

Una función de error evalúa la predicción del modelo. Si hay ejemplos conocidos, una función de error puede hacer una comparación para evaluar la precisión.

Si el modelo puede ajustarse mejor a los puntos de datos en el conjunto de entrenamiento, entonces los pesos se ajustan para reducir la discrepancia entre el ejemplo conocido y la estimación del modelo. El algoritmo repetirá este proceso iterativo de "evaluar y optimizar", actualizando pesos de forma autónoma hasta que se haya cumplido un umbral de precisión [1].

El campo de la **industria cosmética** está viviendo una revolución como consecuencia de las aplicaciones de la Inteligencia Artificial y el Machine Learning. Al igual que sucede en otros sectores donde la experiencia física es importante en la toma de decisión de compra, prestigiosas marcas han apostado por la IA y los algoritmos de aprendizaje automático para prestar un mejor servicio al cliente [3].

## Marco Teórico

**Aprendizaje Supervisado:** El aprendizaje supervisado, también conocido como machine learning supervisado, se define por el uso de conjuntos de datos etiquetados para entrenar algoritmos para clasificar datos o predecir resultados con precisión. A medida que los datos de entrada se introducen en el modelo, éste ajusta sus pesos hasta que se ajustan adecuadamente.

El aprendizaje supervisado ayuda a las organizaciones a resolver una variedad de problemas del mundo real a escala, como clasificar el spam en una carpeta separada de la bandeja de entrada [1].

**Aprendizaje No Supervisado:** El aprendizaje no supervisado, también conocido como machine learning no supervisado, utiliza algoritmos de machine learning para analizar y agrupar conjuntos de datos sin etiquetar (subconjuntos denominados clústeres). Estos algoritmos descubren patrones ocultos o agrupaciones de datos sin necesidad de

intervención humana. La capacidad de este método para descubrir similitudes y diferencias en la información lo hace ideal para el análisis exploratorio de datos, las estrategias de venta cruzada, la segmentación de clientes y el reconocimiento de imágenes y patrones [1].

**Red Convolucional (CNN):** Una red neuronal convolucional (CNN) es un tipo especializado de algoritmo de aprendizaje profundo diseñado principalmente para tareas que requieren reconocimiento de objetos, como la clasificación, la detección y la segmentación de imágenes. Las CNN se emplean en diversos casos prácticos, como vehículos autónomos, sistemas de cámaras de seguridad y otros [2].

**Preprocesamiento de Imágenes:** El preprocesamiento de imágenes es una etapa crucial en el análisis de datos visuales. Incluye técnicas como el redimensionamiento, la normalización de píxeles y el aumento de datos (data augmentation) para mejorar la calidad y diversidad del conjunto de entrenamiento [2].

**Industria cosmética:** La evolución de la Inteligencia Artificial y el Machine Learning en varios sectores, incluidos el sector de belleza, ya era una tendencia en auge, que sin duda ha sido impulsada por el Covid y las restricciones físicas de pruebas de producto y aforos en tiendas. Así, por ejemplo, a día de hoy, ya es posible que el potencial cliente pueda **elegir entre varios modelos** de serum facial o pintalabios **sin necesidad de desplazarse a una tienda para probar directamente distintas muestras**, o acudir a un profesional que les pueda aconsejar sobre aspectos de belleza y dermatología de forma personalizada [3].

## Desarrollo del Modelo de Aprendizaje

### 1. Preprocesamiento de Datos

El conjunto de datos que se utilizará consistirá en imágenes de rostros etiquetadas con su forma correspondiente (por ejemplo, ovalada, redonda, cuadrada, etc.). Se realizarán las siguientes tareas de preprocesamiento:

- **Redimensionamiento:** Todas las imágenes se redimensionarán a un tamaño fijo (por ejemplo, 128x128 píxeles) para garantizar la consistencia en la entrada del modelo.
- **Normalización:** Los valores de los píxeles se escalarán al rango [0, 1] para mejorar la convergencia del modelo durante el entrenamiento.

- **Aumentación de Datos:** Se aplicarán transformaciones como rotaciones, volteos y cambios de brillo para aumentar la diversidad del conjunto de datos y reducir el riesgo de sobreajuste.

## 2. División de Datos

El conjunto de datos se dividirá en dos partes:

- **Entrenamiento (80%):** Se utilizará para entrenar el modelo.
- **Prueba (20%):** Servirá para evaluar el desempeño final del modelo.

## 3. Construcción del Modelo

Se utilizará una **red neuronal convolucional (CNN)** con la siguiente arquitectura:

- **Capa de entrada:** Recibirá imágenes de 128x128 píxeles con 3 canales (RGB).
- **Capas convolucionales:**
  - Primera capa: 32 filtros de 3x3, activación ReLU.
  - Segunda capa: 64 filtros de 3x3, activación ReLU.
  - Tercera capa: 128 filtros de 3x3, activación ReLU.
- **Capas de pooling:** Se aplicará MaxPooling de 2x2 después de cada capa convolucional.
- **Capas fully connected (densas):**
  - Primera capa: 256 neuronas, activación ReLU.
  - Capa de salida: El número de neuronas será igual al número de clases (formas de rostro), con activación softmax.

También se utilizarán varias arquitecturas de una **red neuronal convolucional (CNN)** como la siguiente:

- **Capa de entrada:** Recibirá imágenes de 64x64 píxeles con 3 canales (RGB).
- **Capas convolucionales:**
  - Primera capa: 16 filtros de 3x3, activación ReLU.
  - Segunda capa: 32 filtros de 3x3, activación ReLU.
  - Tercera capa: 64 filtros de 3x3, activación ReLU.

- **Capas de pooling:** Se aplicará MaxPooling de 2x2 después de cada capa convolucional.
- **Capas fully connected (densas):**
  - Primera capa: 128 neuronas, activación ReLU.
  - Capa de salida: El número de neuronas será igual al número de clases (formas de rostro), con activación softmax.

#### 4. Entrenamiento del Modelo

El modelo se compilará utilizando el optimizador **Adam** y la función de pérdida **categorical\_crossentropy**, adecuada para problemas de clasificación multiclase. Se utilizarán las siguientes métricas:

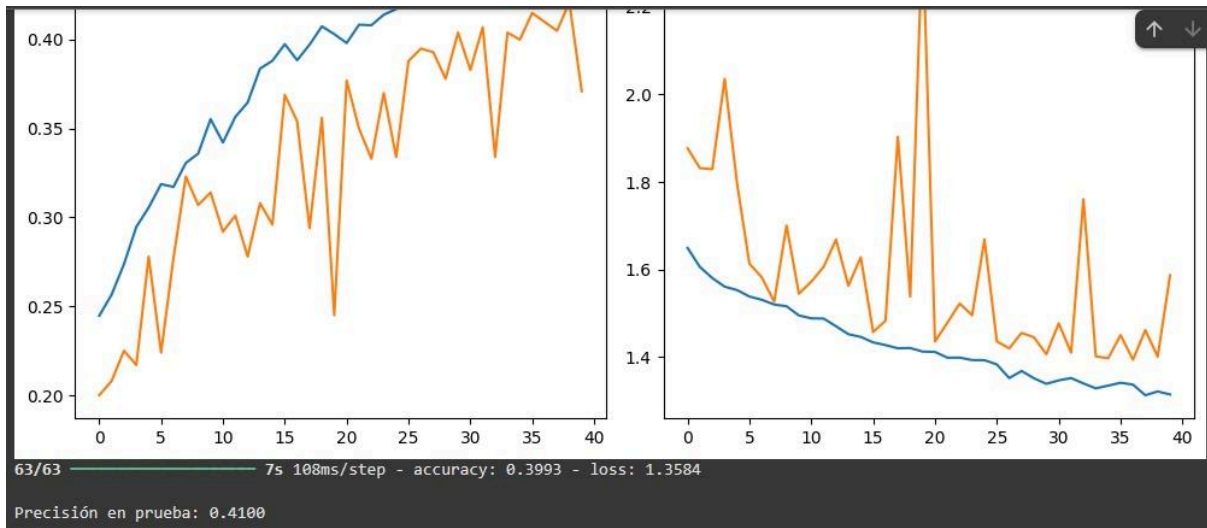
- **Precisión (Accuracy):** Para medir la proporción de predicciones correctas.

El entrenamiento se realizará durante 40 épocas con un tamaño de lote de 32 y también se harán pruebas con un lote de 16 para comparar su eficacia. Se emplearán los callbacks **EarlyStopping** (evita overfitting y detiene el entrenamiento si no hay mejora después de n épocas.) y **ReduceLROnPlateau** (ajusta automáticamente la tasa de aprendizaje cuando el modelo deja de mejorar.) para evitar el sobreajuste y ajustar dinámicamente la tasa de aprendizaje.

#### 5. Resultados

Se espera que el modelo logre una precisión del 90% en el conjunto de pruebas, lo que indicará un buen desempeño en la clasificación y reconocimiento de las formas de rostro. Este nivel de precisión será suficiente para aplicaciones en el sector de belleza. Además se generará una matriz de confusión para visualizar el desempeño del modelo en cada categoría de forma de rostros. Así como que el tiempo que tarda el modelo en realizar la predicción sea inferior a 5 segundos, lo que permitirá su implementación en aplicaciones reales.

Los resultados obtenidos fueron que el modelo obtuvo alrededor de un 40% en nivel de confianza y precisión en la tarea de clasificar rostros por su forma (cuadrada, redonda, circular, etc.). Este nivel de confianza no es suficiente para garantizar que el modelo es certero ni para un uso comercial, profesional o personal.



## 6. Implementación

El modelo será desplegado en una interfaz gráfica accesible mediante una herramienta GUI en este caso Tkinter. Esta interfaz permitirá cargar nuevas imágenes de rostros y obtener información acerca del tipo de rostro, facilitando la aplicación práctica del modelo en entornos personales y empresariales.

## Anexos

Dataset a Utilizar: <https://www.kaggle.com/datasets/niten19/face-shape-dataset/data>

Modelo en colab:

[https://colab.research.google.com/drive/1xAFoak3Ahf3f\\_gEDJbF6YZrgITDEN0Xm?usp=sharing](https://colab.research.google.com/drive/1xAFoak3Ahf3f_gEDJbF6YZrgITDEN0Xm?usp=sharing)

Enlace al repositorio: <https://github.com/Anngel-o/Reconocimiento-Tipos-Rostros-IA>

## Conclusión

El proyecto de Predicción de Formas de Rostros con Imágenes buscará sentar las bases para el desarrollo de sistemas de clasificación de imágenes precisos y robustos que tengan aplicaciones en diversos campos como en el sector de la belleza o incluso en áreas como la seguridad o experiencias de usuario. Los resultados que se obtengan servirán para la mejora continua del proyecto y sus diversas aplicaciones.

El bajo porcentaje de confianza o certeza que obtuvo nuestro modelo, puede deberse principalmente a que el dataset utilizado contenía imágenes dañadas, nuestro modelo aceptó y analizó todas las imágenes que contenía el dataset (incluidas las dañadas), lo que pudo afectar severamente a los resultados esperados. Además se contaba con 1000 ejemplos para cada clase, lo cual si bien es una cantidad medianamente grande, consideramos que esa cantidad está en el rango inferior de cantidad de imágenes necesarias para mejores resultados. Por último es importante mencionar que, es difícil marcar un límite entre cada forma de rostro, incluso para los especialistas en el sector de belleza, donde existe discrepancia en la clasificación de rostros, así como otros parámetros como la percepción de la forma (peinado, barba, ángulo, expresión).

### **Bibliografía**

- [1]. Ibm. (2024, 17 junio). Machine Learning. *IBM*. Recuperado 19 de febrero de 2025, de <https://www.ibm.com/mx-es/topics/machine-learning>
- [2]. *Introducción a las redes neuronales convolucionales (CNN)*. (2024, 16 abril). [www.datacamp.com](https://www.datacamp.com). Recuperado 19 de febrero de 2025, de <https://www.datacamp.com/es/tutorial/introduction-to-convolutional-neural-networks-cnns>
- [3]. Team, K. (2022, 10 noviembre). *Cómo la Inteligencia Artificial y el Machine Learning han cambiado la industria cosmética*. Blog de Kraz | Data Solutions. Recuperado 19 de febrero de 2025, de <https://blog.kraz.ai/marketing/inteligencia-artificial-e-industria-cosmetica-aplicaciones-del-machine-learning/>